

Seoul Bike Sharing Demand Dataset

Kamila Jeannette Martinez Ibarra - A01711833

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Abstract—Este trabajo presenta la implementación de dos modelos para predecir la demanda horaria de bicicletas rentadas en Seúl a partir de variables climáticas y de calendario: una regresión lineal múltiple mediante descenso de gradiente, sin frameworks, y una red neuronal con PCA. Los datos se dividieron en 60% entrenamiento, 20% validación y 20% prueba. El modelo lineal obtuvo un R^2 de 0.5464 y un RMSE de 440.37 en prueba, con bias alto y varianza baja, característico de underfitting. El modelo de red neuronal obtuvo un R^2 de 0.8510 y un RMSE de 242.80, con un bias menor, aunque con un ligero aumento en la varianza al extender el entrenamiento de 200 a 500 épocas. Esto sugiere que la relación entre el clima y la demanda no es completamente lineal.

Index Terms—regresión lineal, redes neuronales, descenso de gradiente, PCA, regularización, bias, varianza

1 INTRODUCCIÓN

LA contaminación del aire debido a los automóviles continúa siendo una de las principales amenazas medioambientales para la salud humana. En la Unión Europea, el transporte es el único sector en el que las emisiones de gases de efecto invernadero han aumentado en las últimas tres décadas, con un incremento del 33.5% entre 1990 y 2019 [1].

Como alternativa a este problema, en varios países desarrollados del mundo las bicicletas se han vuelto una forma positiva y amigable de ayudar al medio ambiente. Sin embargo, para que estos sistemas funcionen bien, las ciudades necesitan predecir con precisión cuántas bicicletas se van a rentar en cada momento, de forma que haya suficiente disponibilidad sin desperdiciar recursos.

Al ser un sistema de renta continuo a lo largo de los años, se tienen varios factores climáticos y de calendario que afectan la demanda de bicicletas. El presente trabajo tiene como objetivo implementar un modelo de regresión lineal para la predicción de bicicletas rentadas en determinada hora del día a partir de un conjunto de datos con factores climáticos y de calendario.

Así mismo, nos asistiremos de métricas que nos permitan evaluar el desempeño del modelo de regresión, como la variabilidad de la demanda de bicicletas o qué tan alejadas están las predicciones del valor real [2].

1.1 Contexto del Conjunto de Datos

El conjunto de datos contiene información de la demanda de bicicletas de la ciudad de Seúl, Corea del Sur. Incluye variables climáticas y la cantidad de bicicletas rentadas por hora [3]. Las instancias abarcan fechas del 1 de diciembre de 2017 hasta el 30 de noviembre de 2018, con un total de 8,760 registros.

1.1.1 Descripción de las características

El conjunto de datos abarca 13 características.

Tabla 1
Descripción de las características del conjunto de datos

Variable	Descripción
Date	Fecha del registro (día/mes/año)
Rented Bike Count	Número de bicicletas rentadas en esa hora (variable objetivo)
Hour	Hora del día (0–23)
Temperature(°C)	Temperatura ambiente en grados Celsius
Humidity(%)	Humedad relativa
Wind speed (m/s)	Velocidad del viento
Visibility (10m)	Visibilidad, en unidades de 10 metros
Dew point temperature(°C)	Temperatura de punto de rocío
Solar Radiation (MJ/m2)	Radiación solar
Rainfall(mm)	Precipitación pluvial
Snowfall (cm)	Precipitación de nieve
Seasons	Estación del año (invierno, primavera, verano, otoño)
Holiday	Indica si el día es festivo o no
Functioning Day	Indica si el sistema de renta estaba operando ese día (Sí/No)

2 ETL

Extracción, transformación y carga (ETL) es el proceso consistente en combinar datos de diferentes orígenes en un gran repositorio central. El proceso consta de tres pasos. Primero se extraen los datos de la fuente origen, seguido de una transformación de estos adecuada al análisis previsto, y finalmente se cargan en un repositorio de datos [4].

2.1 Extracción

Se descargó el conjunto de datos del repositorio de UC Irvine [3]. La extracción se llevó a cabo junto con la librería de Python, pandas, para convertirlo en un dataframe.

2.2 Análisis exploratorio de datos (EDA)

El análisis exploratorio de datos (EDA) tiene como objetivo investigar los conjuntos de datos y resumir las características principales. El propósito del EDA es analizar los datos antes de hacer suposiciones sobre ellos, permitiendo identificar errores, patrones, valores atípicos y relaciones entre variables. Garantizando resultados que sean base para un análisis sofisticado [5].

2.2.1 Histogramas

Los histogramas son útiles para mostrar la distribución de una única variable de escala [6]. Al aplicarlos sobre las variables numéricas del conjunto de datos, se observan distintos patrones de distribución. Rented Bike Count está sesgada a la derecha (Figura 1), ya que la mayoría de las horas registran pocas rentas.




Fig. 1. Distribución de Rented Bike Count

De manera similar, Rainfall(mm), Snowfall (cm) y Solar Radiation (MJ/m2) presentan la mayoría de sus valores en cero (Figura 2), pues llueve, nieva o hay radiación solar plena solo durante una fracción de las horas registradas.




Fig. 2. Distribución de Rainfall(mm), Snowfall (cm) y Solar Radiation

En contraste, Temperature(°C) y Dew point temperature(°C) muestran una distribución más simétrica (Figura 3), cercana a una campana, consistente con el comportamiento anual del clima.




Fig. 3. Distribución de Temperature(°C) y Dew point temperature(°C)

Finalmente, Hour presenta una distribución uniforme (Figura 4), como es de esperarse en una variable que rep-

resenta las 24 horas del día repetidas a lo largo de todo el año.




Fig. 4. Distribución de Hour

2.2.2 Análisis de correlación

La matriz de correlación permite evaluar la fuerza y la dirección de la relación entre dos variables [7]. Los valores de correlación se encuentran entre -1 y +1. Si ambas variables tienden a aumentar o disminuir juntas, la correlación es positiva. Si una aumenta mientras la otra disminuye, la correlación es negativa. Entre más cercano esté el valor a los extremos, más fuerte es la relación. Un valor cercano a 0 indica una relación débil o inexistente.

Para nuestro conjunto de datos realizamos una matriz de correlación, visualizada en un mapa de calor (Figura 5).




Fig. 5. Matriz de Correlación

Al observar la matriz de correlación, destaca que Temperature(°C) y Dew point temperature(°C) están casi perfectamente correlacionadas, 0.91, lo cual indica multicolinealidad [8]. Estas pueden afectar negativamente nuestro modelo de predicción, por lo cual estaremos eligiendo solo una.

En cuanto a la variable objetivo, Rented Bike Count se correlaciona más con Temperature(°C) (0.54), Hour (0.41) y Dew point temperature(°C) (0.38), lo que sugiere que la temperatura y la hora del día son, hasta este punto del análisis, las características con relación más fuerte a la demanda de bicicletas. Por su parte, Humidity(%) presenta una correlación negativa tanto con Rented Bike Count (-0.20) como con Hour (-0.24), y también se correlaciona negativamente con Visibility (10m) (-0.54), lo que indica que los días más húmedos tienden a presentar menor visibilidad y una demanda de bicicletas menor.

El resto de las variables muestran correlaciones lineales débiles con Rented Bike Count.

2.3 Selección de características

A partir de los hallazgos del análisis exploratorio, se realizaron tres eliminaciones sobre el conjunto de datos antes de continuar con la transformación.

2.3.1 Eliminación de Dew point temperature(°C)

Como se observó en la matriz de correlación, esta variable y Temperature(°C) presentan una correlación de 0.91, lo que indica que ambas capturan prácticamente la misma información térmica. Mantener ambas introduciría multicolinealidad en un futuro modelo lineal, por lo que se conservó únicamente Temperature(°C).

2.3.2 Eliminación de Date

Al tratarse de una variable de tipo texto, no puede ser utilizada directamente por un modelo de regresión lineal, el cual requiere que todas las variables predictoras sean numéricas.

2.3.3 Eliminación de instancias con Functioning Day = No

Se eliminaron las instancias en las que Functioning Day tiene el valor No, es decir, las horas en las que el sistema de renta de bicicletas se encontraba cerrado. En estos casos, Rented Bike Count es igual a 0 por definición, sin relación alguna con las condiciones climáticas registradas en esa hora.

2.4 Transformación

2.4.1 Estandarización

Para las variables numéricas, se llevó a cabo una transformación a través de una estandarización de los datos.

Estandarizar los datos significa llevarlos a una escala común, de forma que sea más fácil analizarlos, compararlos y utilizarlos en un modelo. En términos generales, el objetivo es que todas las variables del conjunto de datos queden en la misma escala, normalmente con media 0 y desviación estándar 1 [9].

La estandarización de los datos permite realizar comparaciones justas entre variables. Sin este proceso, aquellas con escalas o varianzas más grandes podrían tener un peso desproporcionado sobre el análisis [9]. En este trabajo, se estandarizaron las siguientes variables:

- Temperature(°C)
- Humidity(%)
- Wind speed (m/s)

- Visibility (10m)
- Solar Radiation (MJ/m²)
- Rainfall(mm)
- Snowfall (cm)

2.4.2 Codificación cíclica de Hour

Bajo una representación lineal, la hora 23 y la hora 0 se encuentran en extremos opuestos del rango de valores, cuando en realidad son consecutivas en el tiempo.

Para resolver esto, se aplicó una codificación cíclica mediante funciones seno y coseno, transformando cada valor de Hour en un ángulo dentro de un círculo:

$$Hour_{sin} = \sin\left(\frac{2\pi \cdot Hour}{24}\right), \quad Hour_{cos} = \cos\left(\frac{2\pi \cdot Hour}{24}\right) \quad (1)$$

Esta transformación preserva la contigüidad entre valores consecutivos del ciclo, de forma que la hora 23 queda cerca de la hora 0, como un reloj.

Es importante utilizar siempre ambos componentes, seno y coseno, en conjunto, ya que el seno por sí solo pierde información de orientación, dado que dos horas distintas pueden compartir el mismo valor de seno [22].

2.4.3 One-Hot Encoding

Para las variables categóricas, se llevó a cabo una codificación One-Hot Encoding. En este tipo de técnica, cada categoría se representa mediante un vector de N elementos, donde N corresponde al número total de categorías posibles. Dentro de este vector, exactamente un elemento toma el valor de 1, mientras que todos los demás permanecen en 0 [10].

Si bien el conjunto de datos cuenta con tres variables categóricas Seasons, Holiday y Functioning Day, únicamente Seasons y Holiday fueron modificadas mediante One-Hot Encoding. Functioning Day no se incluyó en este paso, ya que, como se explicó en la sección de selección de características, las instancias donde esta variable tomaba el valor "No" fueron eliminadas del conjunto de datos por no aportar información relevante al modelo.

2.5 Exportación

Una vez aplicadas las transformaciones explicadas en las secciones anteriores, el nuevo conjunto de datos se exportó a un nuevo archivo, seoul-clean.csv, el cual será utilizado para el entrenamiento del modelo de regresión lineal. El conjunto de datos final quedó conformado por 8,465 instancias y 15 variables (características).

3 MODELO DE REGRESIÓN LINEAL

El modelo de regresión lineal se utiliza para predecir el valor de una variable a partir del valor de otra. A la variable que se desea predecir se le conoce como variable dependiente, mientras que la variable utilizada para predecirla se conoce como variable independiente [11].

Este tipo de análisis estima los coeficientes de una ecuación lineal, la cual puede involucrar una o más variables independientes, que mejor predicen el valor de la variable dependiente [11].

En este trabajo se utilizan múltiples variables independientes para predecir una única variable dependiente, Rented Bike Count, por lo que el modelo empleado corresponde a una regresión lineal múltiple.

3.1 Función de hipótesis

En regresión lineal, el modelo busca ajustar la línea que mejor se ajuste a los datos. Esta línea se conoce como función de hipótesis, y se define como [12]:

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n \quad (2)$$

donde:

- $h_{\theta}(x)$ es el valor predicho
- θ_0 es el bias
- $\theta_1, \dots, \theta_n$ son los parámetros asociados a cada variable independiente
- $x_1, \dots, x_n$ son los valores de dichas variables para una observación dada.

En este trabajo, esta función se implementó en la función $h()$, la cual recorre cada parámetro y lo multiplica por su variable correspondiente, sumando el resultado.

3.2 Función de costo

Una vez que el modelo genera predicciones, es necesario medir qué tan alejadas están de los valores reales. Para ello se utiliza la función de costo, la cual cuantifica el error del modelo en función de sus parámetros actuales. En regresión lineal, la función de costo más utilizada es el error cuadrático medio [13]:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 \quad (3)$$

donde:

- m es el número de observaciones en el conjunto de entrenamiento
- $h_{\theta}(x^{(i)})$ es la predicción para la observación i
- $y^{(i)}$ es su valor real

En el código, esta función corresponde a `show_errors()`, que calcula y almacena el error cuadrático medio en cada época.

3.3 Descenso de gradiente

El descenso de gradiente es un algoritmo de optimización utilizado para encontrar los parámetros que minimizan el error de predicción del modelo, ajustando de forma iterativa dichos parámetros en la dirección donde el error disminuye más rápidamente [14]. Su funcionamiento puede resumirse en los siguientes pasos:

- 1) **Inicialización de parámetros:** se comienza con los parámetros del modelo en cero.
- 2) **Cálculo del error:** en cada época se mide el error del modelo tanto en el conjunto de entrenamiento como en el de validación, con el fin de vigilar el desempeño del modelo durante el entrenamiento.
- 3) **Actualización de parámetros:** los parámetros se ajustan en la dirección que reduce el error, de acuerdo con la tasa de aprendizaje definida.

- 4) **Repetición:** los pasos anteriores se repiten hasta que los parámetros dejan de cambiar de forma significativa, o hasta alcanzar un número máximo de épocas definido de antemano.

La actualización de cada parámetro θ_j se realiza mediante la siguiente regla:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right) x_j^{(i)} \quad (4)$$

donde α es la tasa de aprendizaje (*learning rate*), la cual controla el tamaño del paso en cada actualización.

3.4 Entrenamiento del modelo

Para entrenar el modelo, el conjunto de datos se dividió previamente en tres subconjuntos: entrenamiento, validación y prueba, en una proporción de 60%, 20% y 20% respectivamente. El modelo se entrenó únicamente con el conjunto de entrenamiento, mientras que el conjunto de validación se utilizó para vigilar su desempeño durante el proceso, sin influir directamente en la actualización de los parámetros. El conjunto de prueba se mantuvo completamente al margen del entrenamiento, con el fin de reservarlo para la evaluación final del modelo.

El entrenamiento se realizó con una tasa de aprendizaje $\alpha = 0.01$, deteniéndose cuando el cambio máximo entre los parámetros de una época y la siguiente fue menor a una tolerancia de 1×10^{-6} , o al alcanzar el número máximo de épocas definido para cada corrida.

4 MÉTRICAS DE EVALUACIÓN

4.1 Raíz del Error Cuadrático Medio (RMSE)

El RMSE representa la raíz cuadrada del promedio de las diferencias al cuadrado entre los valores pronosticados y los valores reales, siendo matemáticamente equivalente a la desviación estándar de los residuos del modelo [13]:

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2} \quad (5)$$

A diferencia del MSE, el RMSE se expresa en las mismas unidades que la variable dependiente, lo que facilita su interpretación directa. Al elevar al cuadrado las diferencias antes de sacar la raíz, el RMSE penaliza con mayor severidad los errores grandes en comparación con los pequeños.

4.2 Coeficiente de Determinación (R^2)

El coeficiente de determinación (R^2) indica la cantidad proporcional de variación en la variable de respuesta y explicada por las variables independientes X en el modelo de regresión lineal [15].

$$R^2 = 1 - \frac{SSE}{SST} \quad (6)$$

donde SSE es la suma de cuadrados del error, la diferencia entre los valores predichos y los reales, y SST es la suma de cuadrados total, la diferencia entre los valores reales y su media [16].

4.3 Bias

El bias, también conocido como sesgo, es el error que resulta de la diferencia entre las predicciones promedio de un modelo y los valores reales que se buscan estimar [18]. Un bias alto indica que el modelo es demasiado simple para capturar los patrones en los datos, produciendo predicciones erróneas incluso con datos de entrenamiento distintos. Por el contrario, un bias bajo indica que el modelo logra aproximarse consistentemente a los valores reales, capturando adecuadamente la relación entre las variables predictoras y la variable objetivo [19].

4.4 Varianza

La varianza es el error que refleja qué tan sensible es un modelo a las variaciones específicas del conjunto de datos de entrenamiento con el que fue construido [18]. Una varianza alta indica que el modelo se ajusta demasiado a las particularidades del conjunto de entrenamiento específico, lo que provoca que su desempeño se empeore al evaluarlo con datos nuevos que no vio durante el entrenamiento [19]. En cambio, una varianza baja indica que el modelo es estable, sus predicciones no cambian drásticamente entre distintos conjuntos de entrenamiento.

4.5 Overfitting y Underfitting

El underfitting y el overfitting están directamente determinados por el balance entre bias y varianza de un modelo [20]. El underfitting es característico de modelos con bias alto y varianza baja. Al ser demasiado simples, generan predicciones alejadas del valor real, de ahí el bias alto, pero esa misma simplicidad hace que las predicciones apenas cambien entre distintos conjuntos de entrenamiento, lo que resulta en varianza baja. Por el contrario, el overfitting es característico de modelos con bias bajo y varianza alta. La alta flexibilidad del modelo le permite ajustarse muy de cerca a los datos de entrenamiento, pero esa misma flexibilidad hace que el modelo memorice particularidades específicas de cada conjunto de datos, generando predicciones muy distintas ante datos nuevos y, por lo tanto, varianza alta. El objetivo de un buen ajuste es encontrar el punto donde ambos errores se mantienen bajos de forma simultánea, evitando los dos extremos.

4.6 Regularización

La regularización es una técnica que busca reducir el riesgo de overfitting al restringir la complejidad de un modelo, evitando que se ajuste excesivamente a los casos específicos del conjunto de entrenamiento [20]. Krogh y Hertz [21] demostraron que penalizar el crecimiento de los pesos durante el entrenamiento mejora la capacidad de generalización de una red neuronal. En el caso de weight decay, esto se logra agregando un término a la función de costo que penaliza los pesos grandes, de forma que el modelo prefiera soluciones más simples.

5 RESULTADOS

5.1 Sin framework

El modelo se evaluó de forma iterativa, ajustando dos aspectos del proceso de entrenamiento a partir de los resultados obtenidos: el número de épocas y la inclusión de las instancias con Functioning Day = No.

En una primera corrida, el modelo se entrenó durante 1,000 épocas, utilizando todavía el conjunto de datos completo (8,760 instancias, 17 variables), es decir, sin haber eliminado las instancias de las horas en las que teníamos Functioning Day = No. Esta corrida obtuvo las siguientes métricas:

Tabla 2
Resultados de la Corrida A (1,000 épocas, 8,760 instancias)

Métrica	Valor
RMSE train	431.28
RMSE validation	464.99
RMSE test	454.64
R ² train	0.5377
R ² validation	0.5177
R ² test	0.5113
Gap RMSE (val - train)	33.70
Gap RMSE (test - train)	23.35
Gap R ² (train - val)	0.0200
Gap R ² (train - test)	0.0264

En esta corrida se observa un bias alto y una varianza baja. El bias alto se evidencia tanto en el R², que se mantiene por debajo de 0.54 en los tres conjuntos, como en el RMSE, que se ubica alrededor de 430-465 en los tres casos. Esto indica que el modelo únicamente logra explicar poco más de la mitad de la variabilidad en la demanda de bicicletas, incluso en el conjunto con el que fue entrenado. La varianza, por su parte, se considera baja porque tanto la diferencia en R² como la brecha en RMSE son pequeñas en relación con la magnitud total del error, lo que indica que el desempeño del modelo no cambia drásticamente al evaluarlo con datos que no vio durante el entrenamiento. Esta combinación de bias alto y varianza baja es característica de un modelo con underfitting.

Con el fin de verificar si el modelo aún no había concluido completamente, se incrementó el número de épocas a 5,000, manteniendo el resto del conjunto de datos sin cambios.

Tabla 3
Resultados de la Corrida B (5,000 épocas, 8,760 instancias)

Métrica	Valor
RMSE train	424.14
RMSE validation	456.07
RMSE test	447.38
R ² train	0.5529
R ² validation	0.5360
R ² test	0.5268
Gap RMSE (val - train)	31.93
Gap RMSE (test - train)	23.25
Gap R ² (train - val)	0.0169
Gap R ² (train - test)	0.0261

El RMSE disminuyó ligeramente en los tres conjuntos y el R² aumentó un poco en todos los conjuntos de datos, lo que indica que con 1,000 épocas el modelo aún no había alcanzado la convergencia completa. Sin embargo, las brechas

entre train y validation/test se mantuvieron en magnitudes similares a las de la Corrida A, lo que sugiere que aumentar el número de épocas mejoró el ajuste general del modelo sin modificar el balance entre bias y varianza. El underfitting identificado en la Corrida A se mantiene para esta corrida.

Finalmente, se eliminaron las instancias con Functioning Day = No, como se justificó en la Sección 2.3.3, reduciendo el conjunto de datos a 8,465 instancias y 15 variables. Entrenando nuevamente con 5,000 épocas, el modelo obtuvo los siguientes resultados:

Tabla 4
Resultados de la Corrida C (5,000 épocas, 8,465 instancias, sin Functioning Day = No)

Métrica	Valor
RMSE train	432.69
RMSE validation	448.65
RMSE test	440.37
R ² train	0.5314
R ² validation	0.5374
R ² test	0.5464
Gap RMSE (val - train)	15.95
Gap RMSE (test - train)	7.67
Gap R ² (train - val)	-0.0060
Gap R ² (train - test)	-0.0149

En esta corrida, la brecha entre el RMSE de entrenamiento y el de validation/test disminuyó respecto a las corridas anteriores, y la diferencia en R² se volvió incluso negativa, es decir, el modelo obtuvo un desempeño ligeramente mejor en validación y prueba que en el conjunto de entrenamiento. El bias, sin embargo, se mantiene alto en las tres corridas, ya que tanto el R² como el RMSE no muestran una mejora sustancial en ningún conjunto, lo que refuerza la conclusión de que el modelo presenta underfitting frente a la relación real entre las variables climáticas y de calendario con la demanda de bicicletas.




Fig. 6. Curva de Error




Fig. 7. Predicciones vs Valores Reales

Estos resultados muestran que, si bien aumentar el número de épocas mejoró ligeramente el desempeño del modelo, el cambio con mayor impacto fue la eliminación de las instancias con Functioning Day = No, lo cual redujo notablemente la brecha entre los conjuntos de entrenamiento, validación y prueba, sin resolver el problema de bias alto del modelo lineal.

5.2 Implementación con framework

Con base en los hallazgos reportados en [17], donde se desarrollaron modelos de estimación de tráfico ciclista diario en Portland, Oregón, se seleccionó una arquitectura de red neuronal con 589 neuronas en la capa oculta y función de activación ReLU, aplicando previamente un análisis de componentes principales (PCA) que retiene el 99% de la varianza de los datos. Esta configuración corresponde a la combinación que reportó el mejor desempeño (menor RMSE) en [17].

Adicionalmente, se incorporó una técnica de regularización L2, weight decay, en la capa oculta de la red, con base en los hallazgos de Krogh y Hertz [21], quienes demostraron que penalizar el crecimiento de los pesos durante el entrenamiento mejora la capacidad de generalización de una red neuronal.

El modelo se entrenó inicialmente con 200 épocas, dividiendo el conjunto de datos en 60% entrenamiento, 20% validación y 20% prueba, la misma proporción utilizada en el modelo sin framework.

Tabla 5
Resultados del modelo de red neuronal con PCA (200 épocas)

Métrica	Valor
RMSE train	260.21
RMSE validation	266.93
RMSE test	263.14
R ² train	0.8372
R ² validation	0.8299
R ² test	0.8250
Gap RMSE (val - train)	6.72
Gap RMSE (test - train)	2.93
Gap R ² (train - val)	0.0074
Gap R ² (train - test)	0.0122

A diferencia de las corridas del modelo sin framework, en este caso se observa un bias bajo. Esto se demuestra tanto en el R², que se encuentra por encima de 0.82 en los tres conjuntos, como en el RMSE, que se reduce a un rango de 260-267. Esto indica que el modelo logra explicar más del 82% de la variabilidad en la demanda de bicicletas.

La varianza también se mantiene baja. La diferencia en R² entre entrenamiento y validación y entre entrenamiento y prueba es mínima, al igual que la diferencia en RMSE.

La combinación de bias bajo y varianza baja indica que este modelo logra un buen ajuste, a diferencia del underfitting observado previamente en las tres corridas del modelo sin framework. Esto sugiere que la relación entre las variables climáticas y de calendario con la demanda de bicicletas efectivamente presenta componentes no lineales que el modelo de regresión lineal no fue capaz de capturar.

Con el objetivo de explorar si un mayor número de épocas mejoraba el desempeño del modelo, se incrementó el entrenamiento de 200 a 500 épocas, manteniendo el resto de la configuración sin cambios.

Tabla 6
Comparación del modelo de red neuronal con PCA a 200 y 500 épocas

Métrica	200 épocas	500 épocas
RMSE train	260.21	228.87
RMSE validation	266.93	243.79
RMSE test	263.14	242.80
R ² train	0.8372	0.8741
R ² validation	0.8299	0.8581
R ² test	0.8250	0.8510
Gap RMSE (val - train)	6.72	14.92
Gap RMSE (test - train)	2.93	13.93
Gap R ² (train - val)	0.0074	0.0160
Gap R ² (train - test)	0.0122	0.0231

Al aumentar el número de épocas, tanto el RMSE como el R² mejoraron en los tres conjuntos. Esto indica que el bias del modelo continuó disminuyendo con el entrenamiento adicional, logrando un mejor ajuste general.

Sin embargo, es importante notar que las diferencias entre el conjunto de entrenamiento y los conjuntos de validación y prueba también aumentaron de forma notable. La brecha en RMSE (test - train) pasó de 2.93 a 13.93, y la brecha en R² (train - test) pasó de 0.0122 a 0.0231. Este comportamiento es visible en la Figura 8, donde las curvas de entrenamiento y validación, que se mantenían prácticamente alineadas durante las primeras épocas, comienzan a separarse gradualmente conforme avanza el entrenamiento.




Fig. 8. Curva de RMSE - 500 épocas

Este incremento en la diferencia sugiere que la varianza del modelo comenzó a aumentar conforme se extendió el entrenamiento. En otras palabras, entrenar por más tiempo continuó reduciendo el bias, pero a costa de un ligero aumento en la varianza, un comportamiento consistente con el inicio de un proceso de overfitting hacia las últimas épocas.

6 CONCLUSIÓN

En este trabajo se implementaron dos modelos para predecir la demanda horaria de bicicletas rentadas en Seúl a partir de variables climáticas y de calendario: una regresión lineal múltiple sin frameworks y una red neuronal con PCA.

El modelo lineal, entrenado para 5,000 épocas sobre el conjunto de datos limpio, obtuvo un R² de 0.5464 y un RMSE de 440.37 en prueba. Las distintas corridas mostraron consistentemente un bias alto y una varianza baja, característico de underfitting.

El modelo de red neuronal, entrenado para 500 épocas, obtuvo un R² de 0.8510 y un RMSE de 242.80 en prueba, con un bias considerablemente menor. Sin embargo, al extender el entrenamiento de 200 a 500 épocas, la diferencia entre entrenamiento y prueba también aumentó, sugiriendo un ligero incremento en la varianza.

Estos resultados confirman que la relación entre las variables climáticas y de calendario con la demanda de bicicletas presenta componentes no lineales, y que una red neuronal permite modelarla de forma más precisa que una regresión lineal.

AGRADECIMIENTOS

Me gustaría agradecer a mi familia y amigos :)

REFERENCES

- [1] Parlamento Europeo, "Emisiones de CO₂ de los coches: hechos y cifras (infografía)," Parlamento Europeo, 13 mar. 2019. [En línea]. Disponible: <https://www.europarl.europa.eu/topics/es/article/20190313STO31218/emisiones-de-co2-de-los-coches-hechos-y-cifras-infografia>
- [2] E. Lewinson, "A Comprehensive Overview of Regression Evaluation Metrics," NVIDIA Technical Blog, 20 abr. 2023. [En línea]. Disponible: <https://developer.nvidia.com/blog/a-comprehensive-overview-of-regression-evaluation-metrics/> (link por extrañas razones no funciona)
- [3] "Seoul Bike Sharing demand - UCI Machine Learning Repository." <https://archive.ics.uci.edu/dataset/560/seoul+bike+sharing+demand>
- [4] Amazon Web Services, "¿Qué es extracción, transformación y carga (ETL)?," Amazon Web Services, Inc. <https://aws.amazon.com/es/what-is/etl/>
- [5] "Analytics — IBM," Jun. 07, 2024. <https://share.google/CgtyooGreabQQZVdX>
- [6] "IBM Watson Studio and Knowledge Catalog," Mar. 27, 2025. <https://www.ibm.com/docs/es/ws-and-kc?topic=types-histogram-charts>
- [7] "Interpretar todos los estadísticos y gráficas para Correlación - Minitab," (C) Minitab, LLC. All Rights Reserved. 2026. <https://share.google/ln0nHtHrgAllnLFVV>
- [8] J. Murel PhD and E. Kavlakoglu, "Multicolinealidad," Artificial Intelligence, Nov. 27, 2025. <https://share.google/b4i9OcLyYTsvqPfwJ>
- [9] T. A. S. Srinivas, Y. Sravanthi, Y. V. Kumar, and I. V. D. Srihith, "Data Standardization: Key to effective data integration," Zenodo (CERN European Organization for Nuclear Research), Nov. 2023, doi: 10.5281/zenodo.10060920.
- [10] "Categorical data: Vocabulary and one-hot encoding," Google for Developers. <https://share.google/ZpxwWHIAy5YUN6KhY>
- [11] IBM, "Linear Regression," Think, Nov. 17, 2025. <https://www.ibm.com/think/topics/linear-regression>
- [12] Grasp, "Grasp," Grasp. <https://paths.grasp.study/modules/18a4b167-ba31-4ae3-8084-eeb66f9a9151/lessons/3249a180-bba6-424b-91e2-0e3ad5056997>
- [13] Techietory, "Understanding the cost function in linear regression," Techietory, Feb. 18, 2026. <https://share.google/dkvnZz0UDFSgliOV>
- [14] GeeksforGeeks, "Gradient descent in linear regression," GeeksforGeeks, Jun. 09, 2026. <https://www.geeksforgeeks.org/machine-learning/gradient-descent-in-linear-regression/>
- [15] "Coeficiente de determinación (R cuadrado) - MATLAB Simulink." <https://la.mathworks.com/help/stats/coefficient-of-determination-r-squared.html>
- [16] I. Valchanov, "Sum of squares: SST, SSR, SSE," 365 Data Science, Sep. 19, 2025. <https://365datascience.com/tutorials/statistics-tutorials/sum-squares/>
- [17] M. M. Miah, K. K. Hyun, S. P. Mattingly, and H. Khan, "Estimation of daily bicycle traffic using machine and deep learning techniques," Transportation, vol. 50, no. 5, pp. 1631–1684, Apr. 2022, doi: 10.1007/s11116-022-10290-z.
- [18] "Understanding the Bias-Variance tradeoff." <https://scott.fortmann-roe.com/docs/BiasVariance.html>
- [19] GeeksforGeeks, "Bias and variance in machine learning," GeeksforGeeks, Dec. 12, 2025. <https://www.geeksforgeeks.org/machine-learning/bias-vs-variance-in-machine-learning/>
- [20] T. Mucci, "Overfitting vs. underfitting: Finding the balance," Nov. 17, 2025. <https://www.ibm.com/think/topics/overfitting-vs-underfitting>
- [21] A. Krogh and J. Hertz, "A simple weight decay can improve generalization," 1991. <https://share.google/kBKNEs99LLFjH8l4Z>
- [22] D. Radečić, "How to handle cyclical data in Machine Learning," Towards Data Science, Jan. 27, 2025. <https://towardsdatascience.com/how-to-handle-cyclical-data-in-machine-learning-3e0336f7f97c/>