

Seoul Bike Sharing Demand Dataset

Kamila Jeannette Martinez Ibarra - A01711833

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Abstract—Este trabajo presenta un análisis exploratorio de datos y la implementación desde cero, sin frameworks de machine learning, de un modelo de regresión lineal múltiple mediante descenso de gradiente para predecir la demanda horaria de bicicletas rentadas en Seúl a partir de variables climáticas y de calendario. Los datos se dividieron en conjuntos de entrenamiento, validación y prueba. El modelo obtuvo un R^2 de 0.55 en el conjunto de prueba, es decir, las variables utilizadas logran explicar poco más de la mitad de la variabilidad en la demanda. Esto sugiere que la relación entre el clima y la demanda no es completamente lineal.

Index Terms—instancias

1 INTRODUCCIÓN

La contaminación del aire debido a los automóviles continúa siendo una de las principales amenazas medioambientales para la salud humana. En la Unión Europea, el transporte es el único sector en el que las emisiones de gases de efecto invernadero han aumentado en las últimas tres décadas, con un incremento del 33.5% entre 1990 y 2019 [1].

Como alternativa a este problema, en varios países desarrollados del mundo las bicicletas se han vuelto una forma positiva y amigable de ayudar al medio ambiente. Sin embargo, para que estos sistemas funcionen bien, las ciudades necesitan predecir con precisión cuántas bicicletas se van a rentar en cada momento, de forma que haya suficiente disponibilidad sin desperdiciar recursos.

Al ser un sistema de renta continuo a lo largo de los años, se tienen varios factores climáticos y de calendario que afectan la demanda de bicicletas. El presente trabajo tiene como objetivo implementar un modelo de regresión lineal para la predicción de bicicletas rentadas en determinada hora del día a partir de un conjunto de datos con factores climáticos y de calendario.

Así mismo, nos asistiremos de métricas que nos permitan evaluar el desempeño del modelo de regresión, como la variabilidad de la demanda de bicicletas o qué tan alejadas están las predicciones del valor real [2].

1.1 Contexto del Conjunto de Datos

El conjunto de datos contiene información de la demanda de bicicletas de la ciudad de Seúl, Corea del Sur. Incluye variables climáticas y la cantidad de bicicletas rentadas por hora [3]. Las instancias abarcan fechas del 1 de diciembre de 2017 hasta el 30 de noviembre de 2018, con un total de 8,760 registros.

1.1.1 Descripción de las características

El conjunto de datos abarca 13 características.

Tabla 1
Descripción de las características del conjunto de datos

Variable	Descripción
Date	Fecha del registro (día/mes/año)
Rented Bike Count	Número de bicicletas rentadas en esa hora (variable objetivo)
Hour	Hora del día (0–23)
Temperature(°C)	Temperatura ambiente en grados Celsius
Humidity(%)	Humedad relativa
Wind speed (m/s)	Velocidad del viento
Visibility (10m)	Visibilidad, en unidades de 10 metros
Dew point temperature(°C)	Temperatura de punto de rocío
Solar Radiation (MJ/m2)	Radiación solar
Rainfall(mm)	Precipitación pluvial
Snowfall (cm)	Precipitación de nieve
Seasons	Estación del año (invierno, primavera, verano, otoño)
Holiday	Indica si el día es festivo o no
Functioning Day	Indica si el sistema de renta estaba operando ese día (Sí/No)

2 ETL

Extracción, transformación y carga (ETL) es el proceso consistente en combinar datos de diferentes orígenes en un gran repositorio central. El proceso consta de tres pasos. Primero se extraen los datos de la fuente origen, seguido de una transformación de estos adecuada al análisis previsto, y finalmente se cargan en un repositorio de datos [4].

2.1 Extracción

Se descargó el conjunto de datos del repositorio de UC Irvine [3]. La extracción se llevó a cabo junto con la librería de Python, pandas, para convertirlo en un dataframe.

2.2 Análisis exploratorio de datos (EDA)

El análisis exploratorio de datos (EDA) tiene como objetivo investigar los conjuntos de datos y resumir las características principales. El propósito del EDA es analizar los datos antes de hacer suposiciones sobre ellos, permitiendo identificar errores, patrones, valores atípicos y relaciones entre variables. Garantizando resultados que sean base para un análisis sofisticado [5].

2.2.1 Histogramas

Los histogramas son útiles para mostrar la distribución de una única variable de escala [6]. Al aplicarlos sobre las variables numéricas del conjunto de datos, se observan distintos patrones de distribución. Rented Bike Count está sesgada a la derecha (Figura 1), ya que la mayoría de las horas registran pocas rentas.




Fig. 1. Distribución de Rented Bike Count

De manera similar, Rainfall(mm), Snowfall (cm) y Solar Radiation (MJ/m2) presentan la mayoría de sus valores en cero (Figura 2), pues llueve, nieva o hay radiación solar plena solo durante una fracción de las horas registradas.




Fig. 2. Distribución de Rainfall(mm), Snowfall (cm) y Solar Radiation

En contraste, Temperature(°C) y Dew point temperature(°C) muestran una distribución más simétrica (Figura 3), cercana a una campana, consistente con el comportamiento anual del clima.




Fig. 3. Distribución de Temperature(°C) y Dew point temperature(°C)

Finalmente, Hour presenta una distribución uniforme (Figura 4), como es de esperarse en una variable que rep-

resenta las 24 horas del día repetidas a lo largo de todo el año.




Fig. 4. Distribución de Hour

2.2.2 Análisis de correlación

La matriz de correlación permite evaluar la fuerza y la dirección de la relación entre dos variables [7]. Los valores de correlación se encuentran entre -1 y +1. Si ambas variables tienden a aumentar o disminuir juntas, la correlación es positiva. Si una aumenta mientras la otra disminuye, la correlación es negativa. Entre más cercano esté el valor a los extremos, más fuerte es la relación. Un valor cercano a 0 indica una relación débil o inexistente.

Para nuestro conjunto de datos realizamos una matriz de correlación, visualizada en un mapa de calor (Figura 5).




Fig. 5. Matriz de Correlación

Al observar la matriz de correlación (Figura ??), destaca que Temperature(°C) y Dew point temperature(°C) están casi perfectamente correlacionadas, 0.91, lo cual indica multicolinealidad [8]. Estas pueden afectar negativamente nuestro modelo de predicción, por lo cual estaremos eligiendo solo una.

En cuanto a la variable objetivo, Rented Bike Count se correlaciona más con Temperature(°C) (0.54), Hour (0.41) y Dew point temperature(°C) (0.38), lo que sugiere que la temperatura y la hora del día son, hasta este punto del análisis, las características con relación más fuerte a la demanda de bicicletas. Por su parte, Humidity(%) presenta una correlación negativa tanto con Rented Bike Count (-0.20) como con Hour (-0.24), y también se correlaciona negativamente con Visibility (10m) (-0.54), lo que indica que los días más húmedos tienden a presentar menor visibilidad y una demanda de bicicletas menor.

El resto de las variables muestran correlaciones lineales débiles con Rented Bike Count.

2.3 Selección de características

A partir de los hallazgos del análisis exploratorio, se realizaron tres eliminaciones sobre el conjunto de datos antes de continuar con la transformación.

2.3.1 Eliminación de Dew point temperature(°C)

Como se observó en la matriz de correlación, esta variable y Temperature(°C) presentan una correlación de 0.91, lo que indica que ambas capturan prácticamente la misma información térmica. Mantener ambas introduciría multicolinealidad en un futuro modelo lineal, por lo que se conservó únicamente Temperature(°C).

2.3.2 Eliminación de Date

Al tratarse de una variable de tipo texto, no puede ser utilizada directamente por un modelo de regresión lineal, el cual requiere que todas las variables predictoras sean numéricas.

2.3.3 Eliminación de instancias con Functioning Day = No

Se eliminaron las instancias en las que Functioning Day tiene el valor No, es decir, las horas en las que el sistema de renta de bicicletas se encontraba cerrado. En estos casos, Rented Bike Count es igual a 0 por definición, sin relación alguna con las condiciones climáticas registradas en esa hora.

2.4 Transformación

2.4.1 Estandarización

Para las variables numéricas, se llevó a cabo una transformación a través de una estandarización de los datos.

Estandarizar los datos significa llevarlos a una escala común, de forma que sea más fácil analizarlos, compararlos y utilizarlos en un modelo. En términos generales, el objetivo es que todas las variables del conjunto de datos queden en la misma escala, normalmente con media 0 y desviación estándar 1 [9].

La estandarización de los datos permite realizar comparaciones justas entre variables. Sin este proceso, aquellas con escalas o varianzas más grandes podrían tener un peso desproporcionado sobre el análisis [9]. En este trabajo, se estandarizaron las siguientes variables:

- Temperature(°C)
- Humidity(%)
- Wind speed (m/s)

- Visibility (10m)
- Solar Radiation (MJ/m²)
- Rainfall(mm)
- Snowfall (cm)

Actualmente, me encuentro analizando si estandarizar también la variable Hour mejoraría el desempeño del modelo, dado que se trata de una variable cíclica y, por lo tanto, su escala podría afectar de forma distinta. Esta es una hipótesis que planeo demostrar en trabajo futuro.

2.4.2 One-Hot Encoding

Para las variables categóricas, se llevó a cabo una codificación One-Hot Encoding. En este tipo de técnica, cada categoría se representa mediante un vector de N elementos, donde N corresponde al número total de categorías posibles. Dentro de este vector, exactamente un elemento toma el valor de 1, mientras que todos los demás permanecen en 0 [10].

Si bien el conjunto de datos cuenta con tres variables categóricas Seasons, Holiday y Functioning Day, únicamente Seasons y Holiday fueron modificadas mediante One-Hot Encoding. Functioning Day no se incluyó en este paso, ya que, como se explicó en la sección de selección de características, las instancias donde esta variable tomaba el valor "No" fueron eliminadas del conjunto de datos por no aportar información relevante al modelo.

2.5 Exportación

Una vez aplicadas las transformaciones explicadas en las secciones anteriores, el nuevo conjunto de datos se exportó a un nuevo archivo, seoul-clean.csv, el cual será utilizado para el entrenamiento del modelo de regresión lineal. El conjunto de datos final quedó conformado por 8,465 instancias y 15 variables (características).

3 MODELO DE REGRESIÓN LINEAL

El modelo de regresión lineal se utiliza para predecir el valor de una variable a partir del valor de otra. A la variable que se desea predecir se le conoce como variable dependiente, mientras que la variable utilizada para predecirla se conoce como variable independiente [11].

Este tipo de análisis estima los coeficientes de una ecuación lineal, la cual puede involucrar una o más variables independientes, que mejor predicen el valor de la variable dependiente [11].

En este trabajo se utilizan múltiples variables independientes para predecir una única variable dependiente, Rented Bike Count, por lo que el modelo empleado corresponde a una regresión lineal múltiple.

3.1 Función de hipótesis

En regresión lineal, el modelo busca ajustar la línea que mejor se ajuste a los datos. Esta línea se conoce como función de hipótesis, y se define como [12]:

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n \quad (1)$$

donde:

- $h_{\theta}(x)$ es el valor predicho
- θ_0 es el bias
- $\theta_1, \dots, \theta_n$ son los parámetros asociados a cada variable independiente
- $x_1, \dots, x_n$ son los valores de dichas variables para una observación dada.

En este trabajo, esta función se implementó en la función $h()$, la cual recorre cada parámetro y lo multiplica por su variable correspondiente, sumando el resultado.

3.2 Función de costo

Una vez que el modelo genera predicciones, es necesario medir qué tan alejadas están de los valores reales. Para ello se utiliza la función de costo, la cual cuantifica el error del modelo en función de sus parámetros actuales. En regresión lineal, la función de costo más utilizada es el error cuadrático medio [13]:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 \quad (2)$$

donde:

- m es el número de observaciones en el conjunto de entrenamiento
- $h_{\theta}(x^{(i)})$ es la predicción para la observación i
- $y^{(i)}$ es su valor real

En el código, esta función corresponde a `show_errors()`, que calcula y almacena el error cuadrático medio en cada época.

3.3 Descenso de gradiente

El descenso de gradiente es un algoritmo de optimización utilizado para encontrar los parámetros que minimizan el error de predicción del modelo, ajustando de forma iterativa dichos parámetros en la dirección donde el error disminuye más rápidamente [14]. Su funcionamiento puede resumirse en los siguientes pasos:

- 1) **Inicialización de parámetros:** se comienza con los parámetros del modelo en cero.
- 2) **Cálculo del error:** en cada época se mide el error del modelo tanto en el conjunto de entrenamiento como en el de validación, con el fin de vigilar el desempeño del modelo durante el entrenamiento.
- 3) **Actualización de parámetros:** los parámetros se ajustan en la dirección que reduce el error, de acuerdo con la tasa de aprendizaje definida.
- 4) **Repetición:** los pasos anteriores se repiten hasta que los parámetros dejan de cambiar de forma significativa, o hasta alcanzar un número máximo de épocas definido de antemano.

La actualización de cada parámetro θ_j se realiza mediante la siguiente regla:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right) x_j^{(i)} \quad (3)$$

donde α es la tasa de aprendizaje (*learning rate*), la cual controla el tamaño del paso en cada actualización.

3.4 Entrenamiento del modelo

Para entrenar el modelo, el conjunto de datos se dividió previamente en tres subconjuntos: entrenamiento, validación y prueba, en una proporción de 60%, 20% y 20% respectivamente. El modelo se entrenó únicamente con el conjunto de entrenamiento, mientras que el conjunto de validación se utilizó para vigilar su desempeño durante el proceso, sin influir directamente en la actualización de los parámetros. El conjunto de prueba se mantuvo completamente al margen del entrenamiento, con el fin de reservarlo para la evaluación final del modelo.

El entrenamiento se realizó con una tasa de aprendizaje $\alpha = 0.01$, deteniéndose cuando el cambio máximo entre los parámetros de una época y la siguiente fue menor a una tolerancia de 1×10^{-6} , o al alcanzar un máximo de 10,000 épocas.

4 MÉTRICAS DE EVALUACIÓN

4.1 Error Cuadrático Medio (MSE)

Representa el promedio de las diferencias al cuadrado entre los valores predichos y los valores reales [13]:

$$MSE = \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 \quad (4)$$

Al elevar al cuadrado las diferencias, el MSE penaliza con mayor severidad los errores grandes en comparación con los pequeños.

4.2 Coeficiente de Determinación (R^2)

El coeficiente de determinación (R^2) indica la cantidad proporcional de variación en la variable de respuesta y explicada por las variables independientes X en el modelo de regresión lineal [15].

$$R^2 = 1 - \frac{SSE}{SST} \quad (5)$$

donde SSE es la suma de cuadrados del error, la diferencia entre los valores predichos y los reales, y SST es la suma de cuadrados total, la diferencia entre los valores reales y su media [16].

5 RESULTADOS

El modelo se evaluó de forma iterativa, ajustando dos aspectos del proceso de entrenamiento a partir de los resultados obtenidos: el número de épocas y la inclusión de las instancias con `Functioning Day = No`.

En una primera corrida, el modelo se entrenó durante 2,000 épocas, utilizando todavía el conjunto de datos completo (8,760 instancias, 17 variables), es decir, sin haber eliminado las instancias de las horas en las que teníamos `Functioning Day = No`. Esta corrida obtuvo un MSE de 196,584.73 y un R^2 de 0.5352 en el conjunto de prueba.




Fig. 6.

Con el fin de verificar si el modelo aún no había concluido completamente, se incrementó el número de épocas a 10,000, manteniendo el resto del conjunto de datos sin cambios. El MSE disminuyó a 193,411.99 y el R^2 aumentó ligeramente a 0.5427, lo que indica una mejora marginal y sugiere que el modelo se encontraba cerca de la convergencia incluso con 2,000 épocas.




Fig. 7.

Finalmente, se eliminaron las instancias con Functioning Day = No, como se justificó en la Sección 2.3.3, reduciendo el conjunto de datos a 8,465 instancias y 15 variables (al eliminarse también las columnas dummy Functioning Day_Yes y Functioning Day_No, que quedaban constantes tras el filtro). Entrenando nuevamente con 10,000 épocas, el modelo obtuvo un MSE de 191,644.15 y un R^2 de 0.5517, la mejor combinación de las tres corridas.




Fig. 8.

La Tabla 2 resume los resultados de las tres corridas.

Tabla 2
Comparación de resultados entre corridas

Corrida	Épocas	Instancias	MSE	R^2
1	2,000	8,760	196,584.73	0.5352
2	10,000	8,760	193,411.99	0.5427
3	10,000	8,465	191,644.15	0.5517

Estos resultados muestran que, si bien aumentar el número de épocas mejoró ligeramente el desempeño del modelo, el cambio con mayor impacto fue la eliminación de las instancias con Functioning Day = No.

6 CONCLUSIÓN

En este trabajo se implementó un modelo de regresión lineal múltiple con el objetivo de predecir la demanda horaria de bicicletas rentadas en Seúl a partir de variables climáticas y de calendario.

El modelo final, entrenado durante 10,000 épocas sobre el conjunto de datos depurado, obtuvo un R^2 de 0.5517 y un MSE de 191,644.15 en el conjunto de prueba. Esto indica que las variables climáticas y de calendario consideradas logran explicar poco más de la mitad de la variabilidad observada en la demanda de bicicletas.

AGRADECIMIENTOS

Me gustaría agradecer a mi familia y amigos :)

REFERENCES

- [1] Parlamento Europeo, "Emisiones de CO₂ de los coches: hechos y cifras (infografía)," Parlamento Europeo, 13 mar. 2019. [En línea]. Disponible: <https://www.europarl.europa.eu/topics/es/article/20190313STO31218/emisiones-de-co2-de-los-coches-hechos-y-cifras-infografia>
- [2] E. Lewinson, "A Comprehensive Overview of Regression Evaluation Metrics," NVIDIA Technical Blog, 20 abr. 2023. [En línea]. Disponible: <https://developer.nvidia.com/blog/a-comprehensive-overview-of-regression-evaluation-metrics/> (link por extrañas razones no funciona)
- [3] "Seoul Bike Sharing demand - UCI Machine Learning Repository." <https://archive.ics.uci.edu/dataset/560/seoul+bike+sharing+demand>
- [4] Amazon Web Services, "¿Qué es extracción, transformación y carga (ETL)?," Amazon Web Services, Inc. <https://aws.amazon.com/es/what-is/etl/>
- [5] "Analytics — IBM," Jun. 07, 2024. <https://share.google/CgtyooGreabQQZVdX>
- [6] "IBM Watson Studio and Knowledge Catalog," Mar. 27, 2025. <https://www.ibm.com/docs/es/ws-and-kc?topic=types-histogram-charts>
- [7] "Interpretar todos los estadísticos y gráficas para Correlación - Minitab," (C) Minitab, LLC. All Rights Reserved. 2026. <https://share.google/ln0nHtHrgAllnLFVV>
- [8] J. Murel PhD and E. Kavlakoglu, "Multicolinealidad," Artificial Intelligence, Nov. 27, 2025. <https://share.google/b4i9OcLyYTsvqPfwJ>
- [9] T. A. S. Srinivas, Y. Sravanthi, Y. V. Kumar, and I. V. D. Srihith, "Data Standardization: Key to effective data integration," Zenodo (CERN European Organization for Nuclear Research), Nov. 2023, doi: 10.5281/zenodo.10060920.
- [10] "Categorical data: Vocabulary and one-hot encoding," Google for Developers. <https://share.google/ZpxwWHIAy5YUN6KhY>
- [11] Ibm, "Linear Regression," Think, Nov. 17, 2025. <https://www.ibm.com/think/topics/linear-regression>
- [12] Grasp, "Grasp," Grasp. <https://paths.grasp.study/modules/18a4b167-ba31-4ae3-8084-eeb66f9a9151/lessons/3249a180-bba6-424b-91e2-0e3ad5056997>
- [13] Techietory, "Understanding the cost function in linear regression," Techietory, Feb. 18, 2026. <https://share.google/dkvnZz0UDFS3gliOV>
- [14] GeeksforGeeks, "Gradient descent in linear regression," GeeksforGeeks, Jun. 09, 2026. <https://www.geeksforgeeks.org/machine-learning/gradient-descent-in-linear-regression/>
- [15] "Coeficiente de determinación (R cuadrado) - MATLAB Simulink." <https://la.mathworks.com/help/stats/coefficient-of-determination-r-squared.html>
- [16] I. Valchanov, "Sum of squares: SST, SSR, SSE," 365 Data Science, Sep. 19, 2025. <https://365datascience.com/tutorials/statistics-tutorials/sum-squares/>